

# 코드 분석서

우리가 선택한 모델과, 모델의 개념을 정리하였으며, 비교를 진행하였습니다.

딥러닝에서는 다양한 신경망 구조는 각기 다른 데이터 특성과 문제 유형에 맞게 설계되어 있다. 여기서는 CNN, Transformer, GRU, LSTM의 구조와 특징을 살펴보고, 이러한 모델들을 결합한 CNN+Transformer, CNN+GRU, CNN+LSTM 모델을 사용한 이유를 설명할 것이다.

# ／ 목차

- 1 CNN 구조
- 2 Transformer 구조
- 3 GRU 구조
- 4 LSTM 구조
- 5 CNN과 다른 모델의 결합 이유

# CNN 구조란?



Convolution Neural Network

## 설명

CNN은 이미지나 시계열 데이터와 같은 2차원 데이터의 특징을 추출하는 데 효과적인 신경망이다. 주요 구성 요소는 다음과 같다.

- 합성곱 층(Convolution Layer): 입력 데이터에 필터를 적용하여 특징 맵을 생성한다. 이를 통해 지역적인 패턴을 학습한다.
- 풀링 층(Pooling Layer): 특징 맵의 크기를 줄여, 계산 효율성을 높이고, 과적합을 방지한다.
- 완전 연결 층(Fully Connected Layer): 추출된 특징을 기반으로 최종 출력을 생성한다.

CNN은 이미지 분류, 객체 인식 등 컴퓨터 비전 분야에서 널리 사용된다.

# Transformer 구조란?

## 설명

Transformer는 자연어 처리 분야에서 주로 사용되는 모델로, 시퀀스 데이터를 병렬로 처리할 수 있는 능력을 갖추고 있다. 주요 구성 요소는 다음과 같다.

- 인코더: 입력 시퀀스를 처리하여 내부 표현을 생성한다.
- 디코더: 인코더의 출력을 기반으로 출력 시퀀스를 생성한다.
- 어텐션 메커니즘: 시퀀스 내의 각 요소간의 관계를 파악하여 중요한 정보를 강조한다.

Transformer는 번역, 요약 등 다양한 자연어 처리 작업에서 높은 성능을 보이는 구조이다.

# GRU 구조란?



Gated Recurrent Unit

## 설명

GRU는 순환 신경망(RNN)의 변형으로, 장기 의존성 문제를 해결하기 위해 고안되었다. 주요 특징은 다음과 같다.

- 업데이트 게이트(Update Gate): 이전 상태를 얼마나 유지할지 결정한다.
- 리셋 게이트(Reset Gate): 이전 상태를 얼마나 무시할 지 결정한다.

GRU는 LSTM에 비해 구조가 단순하여 계산 효율성이 높다.

# LSTM 구조란?



Long Short-Term Memory


## 설명

LSTM은 RNN의 장기 의존성 문제를 해결하기 위해 개발된 모델로, 다음과 같은 게이트로 구성된다.

- 입력 게이트: 새로운 정보를 얼마나 저장할지 결정한다.
- 포갯 게이트: 이전 정보를 얼마나 잊을지 결정한다.
- 출력 게이트: 현재 상태를 얼마나 출력할지 결정한다.

LSTM은 긴 시퀀스 데이터에서도 효과적으로 학습할 수 있다.

# CNN과 다른 모델의 결합 이유



## Transformer

1

CNN은 입력 데이터의 지역적 특징을 추출하고, Transformer는 시퀀스 내의 장기 의존성을 학습한다. 이를 통해 이미지나 시계열 데이터의 복잡한 패턴을 효과적으로 학습할 수 있다.

## GRU

2

CNN으로 추출한 특징을 GRU에 입력하여 시퀀스 데이터의 시간적 의존성을 학습한다. GRU의 단순한 구조로 인해 계산 효율성이 높아 실시간 처리에 유효하다.

## LSTM

3

CNN으로 추출한 특징을 LSTM에 입력하여 장기 의존성을 학습한다. LSTM은 긴 시퀀스에서도 학습할 수 있어, 복잡한 시계열 데이터 분석에 적합하다.